

Agentic Workflow Portfolio — 공통 Agent 계약과 Codex/Claude Code Adapter

개인 풀스택 서비스(대학생 룸메이트 매칭, 비공개 저장소)를 AI coding agent와 개발하며 설계·구현한 **agent workflow harness**의

발췌본입니다. 학교 식별 정보는 제거했습니다(프로젝트명 Roommate Matching, 역할 접두어 repo_).

제품 코드는 포함하지 않았으며, 링크의 PR 번호는 비공개 저장소 기준입니다.

풀려고 한 문제

- **AI가 만든 결과를 믿을 근거가 없었다.** Agent의 "완료" 문장, 역할 이름, 설정 파일 존재만으로는 실제 모델·권한·검증이 지켜졌는지 알 수 없었습니다.
- **처음 만든 workflow가 Codex 전용이었다.** 모델·effort·QA 규칙이 Codex에 묶여 있어 Claude Code로 옮기면 같은 품질 절차가 적용되지 않았습니다. (주간 사용량 한도 때문에 host를 바꿔야 하는 실제 상황이 있었습니다.)
- **Hook·설정 같은 통제 장치가 고장 났을 때의 동작이 보장인지 아닌지 구분되지 않았습니다.**

설계 한 줄 요약

공통 계약(요청 권한 → 문서 탐색 → 위임 → 독립 QA → 인계)

- └ Codex adapter : 모델/effort 라우팅, 필수 독립 QA, 복구 규칙, OMX
- └ Claude adapter: 등록된 task만 native subagent 호출, 모델 검사, 결과 수집, 독립 리뷰, 권한 gate
 - └ 새 host : 같은 계약 + conformance test (synthetic 제3 adapter로 검증)

모든 규칙에 강도를 표기합니다: `deterministic-static`(테스트) / `advisory-policy`(문서) / `model-mediated`(agent 판단) /

`native-runtime`(host 강제). 정적 테스트 통과를 실제 모델·권한 입증으로 세지 않습니다.

폴더 안내

경로	내용
AGENTS.md, CLAUDE.md	모든 agent 공통 저장소 지침 / Claude 진입점
docs/development/agent-workflows/	공통 계약(실행·orchestration·QA·위임·계획 lifecycle)과 <code>adapters/</code> (Codex·Claude·교차 인계)

docs/development/agentic-engineering-methodology.md	채택한 방법론과 적용 수준(과장 금지 원칙 포함)
docs/development/agentic-orchestration-case-study.md	Codex 단계의 parent-subagent 설계 case study
.codex/, .claude/	역할 정의(TOML/Markdown), Claude hook·권한 설정
scripts/agents/{common,codex,claude,bridge}	계약을 실제로 소비하는 코드(정책·등록·hook·collector·preflight)
scripts/ci/*.test.mjs	위 코드의 회귀·negative 테스트
EVIDENCE.md	실제로 확인된 결과와 수치
ROADMAP.md	설계만 존재하거나 검증 대기인 항목

이 발췌본은 원 저장소의 다른 문서(제품 정책, GitHub 전략 등)를 포함하지 않으므로 일부 상대 링크는 열리지 않습니다.

확인된 결과 (2026-09-28 기준)

"확인됨"은 병합된 PR, CI, 테스트 실행 출력 또는 실제 세션 기록으로 확인한 것만 적었습니다.

PR 번호는 비공개 저장소 기준입니다.

1. 통합된 변경

단위	내용	상태
공통 계약 재 설계	71개 개발 문서를 문서 graph로 감사, host-neutral 계약·계획 lifecycle·adapter conformance	PR #484 병합
Codex 재접 합	Codex도 공통 계약을 소비하도록 재연결, 기존 모델/QA/복구 동작 회귀 고정, preflight 버그 수정	PR #485 병합
Claude adapter	진입점·task 등록·hook·결과 수집·독립 리뷰·권한 gate	PR #487 진행 중(최종 commit CI 11/11 통과, 병합 전)

2. 테스트

- Claude/Codex/공통 workflow 대상 테스트: **467/467 통과**, 저장소 전체 정책 테스트 **1116/1116 통과**
(최신 작업 트리 기준. 병합 전 최종 commit 기준은 1105/1105).
- Negative 테스트 예: 모델 누락·불일치, 다른 세션, 만료, 입력 변조, 재사용, 권한 모드 변경, 독립 리뷰어가 자기 자신을

검토하는 경우, 리뷰 결과를 다른 리뷰어로 바꿔치기하는 경우, 이미 실행된 작업에 뒤늦게 권한을 붙이는 경우.

3. 실제 Claude Code 세션에서 관측한 것 (일반 auto 모드)

관측	결과
----	----

잘못된 모델·모델 누락 요청	실행 전 hook이 거부, subagent 0개 (여러 회)
입력 파일이 등록 후 바뀐 요청	<code>input file drift</code> 로 거부
Sonnet executor 구현 → Opus 독립 reviewer → 공통 QA	완료 판정 통과. 변경 파일 1개(2,900개 경로 대조), writer lease 회수
Sonnet researcher 결과	Opus 독립 reviewer가 공식 문서에 없는 주장(과잉 인용)을 FAIL로 적발, Parent가 원문으로 재현, 완료 거부
Haiku explorer	정확한 모델 ID와 oracle 일치 확인
권한 grant 없이 실행된 subagent	모델·결과가 맞아도 완료 판정 거부(missing-permission-grant)

4. 독립 리뷰가 실제로 잡아낸 결함

- 소스 리뷰 1라운드 FAIL(중간 3건): 리뷰어 "쇼핑"(FAIL 뒤 다른 리뷰어 PASS로 우회), 빈 JSON 결과 통과, 리뷰어가

실행 주체를 겸함 → 테스트로 재현 후 수정.

- 2라운드 FAIL(중간 1건): 전달됐지만 기록되지 않은 FAIL 우회 → 수정. 3라운드 PASS.
- 권한 gate 리뷰: 이미 실행된 작업에 나중에 권한을 발급하는 우회 → 재현·수정 후 PASS.

5. 공식 문서 대조로 바뀐 설계

- Claude Code 공식 hooks 문서 확인 결과, hook이 실패하면 호출이 그대로 진행됩니다(fail-open).
- 이를 근거로 "hook만으로 막는다"는 가정을 버렸습니다. 대신 역할별 ask 권한 규칙 + `PermissionRequest` hook 구조로 바뀌,

hook이 고장 나면 자동 승인되지 않고 **사람의 승인 요청으로 넘어가도록**(fail-safe to human) 설계했습니다.

새 세션에서의 실측은 대기 중입니다(ROADMAP 참조).

설계·검증 대기 항목 (구현 완료 아님)

아래는 계획 문서에만 있거나 실측이 끝나지 않은 항목입니다. 완료로 주장하지 않습니다.

항목	상태	내용
권한 gate 실측	구현·리뷰 완료, live 검증 대기	정상 / hook 부재 / timeout / 잘못된 출력 / deny 규칙의 7개 시나리오를 새 세션에서 실행해 "고장 시 사람 승인으로 넘어가는지" 확인
Claude subagent 아키텍처 재설계	설계	모델과 effort를 함께 고르는 profile(역할 × 모델 × effort 단계), 관측된 effort와 기대값 대조, 실패 원인별 복구(정보 충분한데 오답이면 상위 모델, 누락·중단이면 effort 상향; 공식 권고 근거)
운영 helper	설계	수작업 JSON 없이 task 등록·독립 리뷰 packet을 만드는 명령, Parent 동시 쓰기 차단
공통 지침 누락 점검	설계	Codex 문서에만 있는 일반 원칙(복구 한도, 품질 stop 등)을 공통 계약으로 승격
교차 host 리뷰 실행기	설계 (현재 fake process만)	Claude Lead ↔ Codex CLI 단발성 읽기 전용 리뷰, 인증·권한·정리 검증

통합 live 자격 검증	설계	양방향 maker/checker, 계획 연계(Codex ↔ Claude), OMC/OMX 수명주기
---------------	----	--

알려진 한계: hook 기반 통제는 사람이 승인 요청을 수락하면 막지 못합니다(대신 완료 판정에서 거부). 생산성이 나 품질 향상 수치는 측정하지 않았습니다.